30 Roteiros

Oct 15, 2026 · @Lucca

Como usar

São 30 vídeos independentes, cada um abrindo uma peça técnica real da IA: o mecanismo, a conta e o número na tela, sem pular a matemática, mas explicando cada passo. Sete são longos (100 a 120 s). A ordem é a sugerida para postar; o 01 foi mantido como estreia porque usa os dados reais já validados.

Formato de cada roteiro: título e duração · capa · **Termos na tela** (as palavras técnicas que aparecem escritas no vídeo, para o público aprender o vocabulário) · tabela Tempo · Narração · Na tela.

Todo vídeo termina com o Fechamento padrão do Manual da Marca: "Turno encerrado." + apito + placa de aviso.

REAL = dado verdadeiro (tokenizador do GPT-4o, conta feita, número publicado em artigo). **ILUSTRATIVO** = representação. Os números de exemplo das contas (notas, porcentagens, perdas) foram calculados de verdade e podem ir para a tela.

Nº	Vídeo	Duração
01	A IA não lê palavras: tokens e IDs	60 s
02	Como o vocabulário da IA foi criado (BPE)	75 s
03	Palavras viram coordenadas: embeddings	75 s
04	Rei − homem + mulher = rainha	55 s
05	LONGO · Atenção por dentro: Query, Key e Value	120 s
06	A IA não sabe a ordem das palavras	60 s
07	LONGO · O bloco que se repete 96 vezes: o Transformer	110 s
08	Logits e softmax: como notas viram probabilidade	60 s
09	Temperatura, com a conta na tela	55 s
10	Top-k e top-p: cortando a roleta	55 s
11	A única coisa que a IA aprende a fazer: a função de perda	65 s

Nº	Vídeo	Duração
12	LONGO · Gradiente descendente e backpropagation	110 s
13	LONGO · Do modelo base ao assistente: SFT, RLHF e DPO	120 s
14	O que são 175 bilhões de parâmetros, e quanto pesam	60 s
15	Quantização: como uma IA cabe no seu computador	60 s
16	Leis de escala e o erro de 2020	65 s
17	Por que contexto longo é caro: atenção quadrática	55 s
18	KV cache: por que a primeira palavra demora	60 s
19	Por que a resposta custa mais caro que a pergunta	55 s
20	Prompt caching	55 s
21	Mixture of Experts: o modelo que usa só parte do cérebro	60 s
22	Speculative decoding: o modelo pequeno que chuta	60 s
23	Tool calling por dentro: a IA só escreve JSON	65 s
24	MCP por dentro	70 s
25	LONGO · O que é um agente, de verdade: o loop	100 s
26	LONGO · RAG por dentro, passo a passo	110 s
27	Modelos de raciocínio: o que é o "pensando..."	75 s
28	Como a IA vê uma imagem	60 s
29	LONGO · Como a IA gera imagem: difusão	100 s
30	Superposição: mais conceitos que neurônios	75 s

Vídeos 01 a 05

01 · A IA não lê palavras: tokens e IDs (60 s)

Capa: **A IA não lê palavras** · Termos na tela: token · tokenizador · vocabulário · ID

Tempo	Narração	Na tela
0–3 s	Você escreve "coração". A IA recebe "c" e "oração".	Guilhotina corta a caixa "coração" em c · oração. REAL
3–8 s	E isso explica metade dos erros bobos que ela comete. Vou te mostrar o que entra de verdade na máquina.	Placa: TOKENIZADOR
8–20 s	O primeiro passo de qualquer modelo de linguagem é o tokenizador. Ele corta o texto em pedaços que existem num vocabulário fixo. O do GPT-4o tem cerca de 200 mil pedaços.	Um catálogo gigante folheando: "200.000 tokens". REAL
20–32 s	"Qual a capital do Brasil?" vira seis tokens. Repara que o espaço vai grudado no começo da palavra seguinte.	6 caixas: Qual · ␣a · ␣capital · ␣do · ␣Brasil · ?. REAL
32–42 s	Cada token é trocado pela posição dele no catálogo: 16752, 261, 9029, 621, 15278, 30. A rede neural nunca vê letra nenhuma. Vê essa lista.	Carimbadora aplicando os IDs em azul. REAL
42–52 s	Por isso "Brasil" com espaço é o 15278 e sem espaço é o 154908: são entradas diferentes do catálogo. E por isso contar letras dentro de uma palavra é difícil para ela: as letras ficaram dentro da caixa.	Sirene; duas caixas com IDs diferentes; "morango" vira mor · ango, letras invisíveis. REAL
52–60 s	Fechamento padrão.	Placa de aviso

02 · Como o vocabulário da IA foi criado (75 s)

Capa: **Ninguém escolheu essas palavras** · Termos na tela: BPE · Byte Pair Encoding · merge · vocabulário

Tempo	Narração	Na tela
0–3 s	Ninguém escolheu as 200 mil peças que a IA usa para ler. Um algoritmo escolheu.	Catálogo de tokens com um carimbo: "FEITO POR ALGORITMO"
3–10 s	Ele se chama BPE, nasceu nos anos 90 para compactar arquivos e foi adaptado para linguagem em 2016. A regra cabe numa frase.	Placa: TOKENIZADOR · ficha "BPE · 1994 / 2016"
10–18 s	Comece com letras soltas. Conte quais duas peças aparecem lado a lado mais vezes. Junte essas duas numa peça nova. Repita.	3 passos numerados aparecendo
18–30 s	Rodei isso agora num texto pequeno: casa, casado, casamento, caso, coisa. Passo 1: "c" e "a" aparecem juntos 9 vezes. Viram "ca".	Letras soltas na esteira; "c"+"a" se fundem em "ca", contador 9×. REAL
30–42 s	Passo 2: "ca" com "s". Passo 3: "cas" com "a". Pronto: "casa" virou uma peça só. Dois passos depois, "casado" também.	Fusões em sequência: ca → cas → casa → casad → casado. REAL
42–52 s	Mas olha "coisa": apareceu pouco, continua picada em letras. Palavra frequente vira uma peça. Palavra rara fica em pedaços.	Sirene; "c · o · i · s · a" separada ao lado de "casa" inteira. REAL
52–66 s	Agora imagina isso rodando em bilhões de páginas, quase sempre em inglês, até ter 200 mil peças. É por isso que "coração" se partiu, que palavras em português gastam mais tokens e que a IA tropeça em palavras raras.	Zoom out: catálogo enchendo; peças em inglês grandes, em português picadas. ILUSTRATIVO
66–75 s	Fechamento padrão.	Placa de aviso

03 · Palavras viram coordenadas: embeddings (75 s)

Capa: **A IA guarda palavras num mapa** · Termos na tela: embedding · vetor · dimensão · similaridade de cosseno

Tempo	Narração	Na tela
0–3 s	Para a IA, "cachorro" e "gato" moram perto. "Cachorro" e "geladeira", não.	Duas caixas lado a lado numa prateleira; a geladeira longe
3–8 s	Isso é literal. Existe um mapa. E ele tem milhares de dimensões.	Placa: ALMOXARIFADO
8–20 s	Depois do tokenizador, cada ID puxa uma linha de uma tabela gigante. Essa linha é uma lista de números: o embedding. No GPT-3, cada token virava 12.288 números.	O ID 15278 abre uma gaveta e sai uma fita longa de números. REAL (GPT-3, 2020)
20–34 s	Pensa em cada lista como uma seta num espaço. Palavras usadas em contextos parecidos acabam com setas apontando para direções parecidas.	Setas saindo do centro; "cachorro" e "gato" quase juntas. ILUSTRATIVO
34–48 s	Para medir isso, a IA usa o cosseno do ângulo entre as setas. Mesma direção: 1. Perpendicular, sem relação: 0. Opostas: menos 1.	Fórmula: cos(θ) = (A·B) / (‖A‖·‖B‖); exemplo [1, 2] e [2, 4] → 1,0; [1, 2] e [−1; 0,5] → 0,0. REAL (conta)
48–62 s	E o mais incrível: ninguém escreveu esses números. Eles começam aleatórios e vão sendo ajustados no treino até que a geometria do mapa reflita o significado.	Sirene; setas embaralhadas se organizando
62–68 s	Essa ideia de "significado como posição" é a base de busca semântica, RAG e recomendação.	Três etiquetas acendendo
68–75 s	Fechamento padrão.	Placa de aviso

04 · Rei − homem + mulher = rainha (55 s)

Capa: **Fizeram conta com palavras** · Termos na tela: word2vec · aritmética vetorial · direção semântica

Tempo	Narração	Na tela
0–3 s	Rei, menos homem, mais mulher. Dá rainha. Isso é uma conta de verdade.	A equação montada com caixas: rei − homem + mulher = ?

Tempo	Narração	Na tela
3–10 s	Em 2013, pesquisadores do Google mostraram isso com um modelo chamado word2vec.	Placa: ARQUIVO HISTÓRICO · ficha "word2vec · Mikolov et al. · 2013"
10–24 s	Cada palavra é uma seta. A diferença entre "homem" e "mulher" é uma direção no mapa. A diferença entre "rei" e "rainha" é praticamente a mesma direção.	Duas setas paralelas: homem→mulher e rei→rainha. ILUSTRATIVO
24–36 s	Então, se você parte de "rei", tira a direção "homem" e soma a direção "mulher", a palavra mais próxima de onde você chega é "rainha".	Animação: a seta "rei" anda, e a palavra mais próxima acende: rainha
36–46 s	Funciona com outras relações: Paris menos França mais Itália cai perto de Roma. O modelo nunca recebeu uma tabela de capitais. Ele tirou isso só de ver como as palavras aparecem.	Sirene; segunda equação com países e capitais
46–50 s	Não é exato: é "a palavra mais próxima". Mas mostra que significado virou geometria.	Selo "APROXIMADO"
50–55 s	Fechamento padrão.	Placa de aviso

05 · LONGO · Atenção por dentro: Query, Key e Value (120 s)

Capa: **O mecanismo que criou o ChatGPT** · Termos na tela: atenção · query · key · value · softmax · máscara causal · multi-head

Tempo	Narração	Na tela
0–4 s	"Banco" pode ser onde você senta ou onde você saca dinheiro. Como a IA decide? Com o mecanismo mais importante da IA moderna.	Caixa "banco" com um banco de praça e um cofre desenhados
4–12 s	Ele se chama atenção. Vou abrir a máquina e mostrar a conta.	Placa: SALA DE REUNIÃO

Tempo	Narração	Na tela
12–26 s	Frase: "Ele foi ao banco sacar dinheiro". Cada token já virou uma lista de números. Agora, cada um passa por três multiplicações aprendidas no treino e gera três versões de si mesmo.	A caixa "banco" passa por três prensas e sai com três etiquetas: Q, K, V
26–38 s	Query é a pergunta: "o que eu estou procurando?". Key é a etiqueta: "o que eu ofereço?". Value é o conteúdo que eu entrego se alguém me escolher.	Três cartões explicativos
38–52 s	"banco" pega a sua Query e compara com a Key de cada palavra anterior, multiplicando os números par a par e somando. Dá uma nota de afinidade para cada uma.	Linhas de "banco" até "Ele", "foi", "ao"; notas surgindo em azul. ILUSTRATIVO
52–62 s	Essas notas são divididas pela raiz quadrada do tamanho do vetor, para não explodirem, e passam pelo softmax, que transforma tudo em porcentagens que somam 100%.	Fórmula: softmax(Q·K^T / √d)
62–76 s	Aí "banco" recebe uma mistura dos Values, pesada por essas porcentagens. Se "sacar" e "dinheiro" ganharam peso alto, "banco" absorve esse sentido. O vetor dele muda. Agora ele é o banco do dinheiro.	Fórmula completa: Atenção = softmax(Q·K^T / √d) · V; a caixa "banco" muda de cor e o cofre fica
76–88 s	Detalhe: num modelo como o ChatGPT, cada palavra só olha para trás. Uma máscara esconde o futuro, porque na hora de gerar texto o futuro ainda não existe.	Sirene; uma cortina cobrindo as caixas à direita
88–102 s	E não é uma reunião só. São várias cabeças de atenção em paralelo, cada uma aprendendo um tipo de relação: gramática, quem é sujeito, o que se refere a quê. O GPT-3 tinha 96 cabeças em cada camada.	96 mini-salas lado a lado. REAL (GPT-3, 2020)

Tempo	Narração	Na tela
102–112 s	Foi esse mecanismo, publicado pelo Google em 2017, que permitiu o salto que levou ao ChatGPT.	Ficha: "Attention Is All You Need" · 2017
112–120 s	Fechamento padrão.	Placa de aviso

Vídeos 06 a 10

06 · A IA não sabe a ordem das palavras (60 s)

Capa: **Para a IA, a ordem não existe** · Termos na tela: codificação posicional · invariância à permutação · RoPE · rotação

Tempo	Narração	Na tela
0–3 s	"O cachorro mordeu o homem" e "o homem mordeu o cachorro". Para a atenção pura, são a mesma frase.	As duas frases em caixas; um sinal de igual em vermelho
3–8 s	E o jeito que resolveram isso é genial.	Placa: ETIQUETADORA
8–20 s	A atenção compara cada palavra com cada outra, mas não sabe quem veio antes. Embaralhe as caixas e o resultado de cada uma é o mesmo. Isso tem nome: invariância à permutação.	As caixas embaralhando sobre a esteira, com o mesmo resultado em cada uma
20–32 s	O Transformer original, de 2017, somava a cada token um padrão de ondas de frequências diferentes. Cada posição ganhava uma impressão digital única.	Ondas senoidais coladas como etiqueta em cada caixa
32–46 s	Os modelos modernos usam outra ideia, o RoPE: girar o vetor de cada token por um ângulo proporcional à posição. A palavra 1 gira um pouco, a palavra 10 gira mais.	Setas girando, cada uma num ângulo maior. ILUSTRATIVO

Tempo	Narração	Na tela
46–54 s	Quando duas setas giradas se comparam, o resultado passa a depender da distância entre elas. Assim a atenção ganha noção de perto e longe.	Sirene; duas setas com o ângulo entre elas destacado
54–60 s	Fechamento padrão.	Placa de aviso

07 · LONGO · O bloco que se repete 96 vezes: o Transformer (110 s)

Capa: **A peça que se repete 96 vezes** · Termos na tela: bloco Transformer · camada · MLP · conexão residual · normalização · d_model

Tempo	Narração	Na tela
0–4 s	O GPT-3 era a mesma peça repetida 96 vezes, uma em cima da outra. Vou abrir essa peça.	Prédio de 96 andares iguais. REAL (GPT-3, 2020)
4–10 s	Ela se chama bloco Transformer, e tem quatro partes.	Placa: LINHA DE MONTAGEM; um andar em corte
10–24 s	Parte 1, atenção: as palavras trocam informação entre si. É onde "banco" descobre que é o banco do dinheiro.	Mini sala de reunião dentro do andar
24–40 s	Parte 2, MLP: cada palavra é processada sozinha por uma rede que expande o vetor e depois comprime de volta. No GPT-3, de 12.288 números para 49.152, e de volta. Pesquisas sugerem que boa parte dos fatos memorizados mora aqui.	Uma caixa entra numa máquina, estica para 4× o tamanho e volta. REAL (GPT-3)
40–56 s	Parte 3, a conexão residual: o resultado da atenção e da MLP não substitui o vetor. É somado a ele. Cada andar adiciona uma correção a uma esteira que atravessa o prédio inteiro.	Sirene; uma esteira vertical atravessando todos os andares, com cada andar depositando algo nela

Tempo	Narração	Na tela
56–66 s	Parte 4, normalização: antes de cada etapa, os números são reescalados para não crescerem ou sumirem ao longo de dezenas de andares.	Uma régua ajustando as caixas para o mesmo tamanho
66–82 s	Empilhe isso. O GPT-2 pequeno tinha 12 andares e vetores de 768 números. O GPT-3, 96 andares e 12.288 números. Os modelos atuais não divulgam esses números, mas a receita é a mesma.	Dois prédios lado a lado: 12 andares e 96 andares. REAL (artigos de 2019 e 2020)
82–98 s	No último andar, o vetor da última palavra é multiplicado por uma tabela com uma linha para cada token do vocabulário. Sai uma nota para cada uma das palavras possíveis. Essa nota é o que decide o que ela vai escrever.	O topo do prédio vira o painel de apostas
98–110 s	Fechamento padrão.	Placa de aviso

08 · Logits e softmax: como notas viram probabilidade (60 s)

Capa: **A conta por trás de cada palavra** · Termos na tela: logit · softmax · exponencial · distribuição de probabilidade

Tempo	Narração	Na tela
0–3 s	Antes de escolher uma palavra, a IA dá uma nota para todas. Inclusive nota negativa.	Painel com notas, algumas negativas
3–8 s	Essas notas se chamam logits. E tem uma conta que transforma elas em porcentagem.	Placa: BALANÇA
8–20 s	Exemplo: depois de "O céu está", digamos que "azul" tirou 4, "nublado" tirou 2 e "verde" tirou 1.	Três caixas com as notas 4, 2, 1 em azul
20–34 s	A conta se chama softmax. Eleve o número e, que vale cerca de 2,718, a cada nota. Depois divida cada resultado pela soma de todos.	Fórmula: $p = e^x / \Sigma e^x$

Tempo	Narração	Na tela
34–46 s	Resultado: azul, 84,4%. Nublado, 11,4%. Verde, 4,2%. Fiz a conta: soma 100.	Fatias da balança: 84,4 · 11,4 · 4,2. REAL (conta)
46–54 s	Repara no efeito da exponencial: 2 pontos de diferença na nota viraram uma chance cerca de 7 vezes maior. Pequenas diferenças lá dentro viram certezas aqui fora.	Sirene; "×7,4" entre azul e nublado
54–60 s	Fechamento padrão.	Placa de aviso

09 · Temperatura, com a conta na tela (55 s)

Capa: **O que a temperatura faz de verdade** · Termos na tela: temperatura · logit / T · greedy · amostragem

Tempo	Narração	Na tela
0–3 s	A "criatividade" da IA é uma divisão. Uma só.	Alavanca TEMPERATURA e o símbolo ÷
3–8 s	Mesmo exemplo de antes: azul 4, nublado 2, verde 1.	Placa: ROLETA; as três notas
8–20 s	A temperatura divide as notas antes do softmax. Temperatura 1: nada muda. Azul 84,4%, nublado 11,4%, verde 4,2%.	Fórmula: p = softmax(logits / T); fatias 84,4 · 11,4 · 4,2. REAL (conta)
20–32 s	Temperatura 0,5: as notas dobram e as diferenças crescem. Azul vai para 98%. Nublado 1,8%. Verde 0,2%. Quase sempre o óbvio.	Alavanca para baixo; fatias 98,0 · 1,8 · 0,2. REAL (conta)
32–44 s	Temperatura 2: as notas caem pela metade e as fatias se aproximam. Azul 62,9%, nublado 23,1%, verde 14%. Agora "verde" sai uma vez a cada sete.	Alavanca para cima; fatias 62,9 · 23,1 · 14,0. REAL (conta)
44–50 s	No limite, temperatura perto de zero vira sempre a primeira opção. Isso se chama decodificação gulosa.	Sirene; a roleta trava em "azul"

Tempo	Narração	Na tela
50–55 s	Fechamento padrão.	Placa de aviso

10 · Top-k e top-p: cortando a roleta (55 s)

Capa: **A IA corta opções antes de sortear** · Termos na tela: top-k · top-p · nucleus sampling

Tempo	Narração	Na tela
0–3 s	A IA tem 200 mil palavras na roleta. Mas quase nunca sorteia entre todas.	Roleta com 200 mil fatias finíssimas
3–8 s	Existem duas tesouras que cortam a roleta antes do sorteio.	Placa: ROLETA; duas tesouras
8–20 s	A primeira é o top-k: fica só com as k opções mais prováveis. Com k igual a 50, as outras 199.950 saem. Com k igual a 1, ela vira determinística.	Tesoura corta tudo menos 50 fatias
20–36 s	A segunda é o top-p, de 2019: fica com o menor grupo de opções que soma pelo menos p. Com p de 90%, no nosso exemplo: azul 84,4 mais nublado 11,4 dá 95,8. Já passou de 90. Verde é cortado.	Fatias somando até a linha de 90%; "verde" cai. REAL (conta)
36–48 s	A vantagem: quando a IA está segura, sobram poucas opções. Quando está em dúvida, sobram muitas. O corte se adapta.	Sirene; duas roletas: uma com 2 fatias, outra com 40
48–50 s	Tudo isso é configuração de quem roda o modelo, não do modelo.	Painel de controle com três botões: T, k, p
50–55 s	Fechamento padrão.	Placa de aviso

Vídeos 11 a 15

11 · A única coisa que a IA aprende a fazer: a função de perda (65 s)

Capa: **A IA é treinada para ter menos surpresa** · Termos na tela: função de perda · entropia cruzada · −ln(p) · perplexidade

Tempo	Narração	Na tela
0–3 s	Uma IA como o ChatGPT foi treinada para minimizar um único número.	Um mostrador gigante com um número caindo
3–8 s	Esse número mede surpresa. E toda a "inteligência" saiu dele.	Placa: CONTROLE DE QUALIDADE
8–20 s	No treino, a IA lê um trecho real e tenta prever o próximo token. Aí a gente olha qual chance ela deu para a palavra que de fato veio.	Uma frase com a última palavra coberta; a IA aposta; a palavra é revelada
20–36 s	A perda é menos o logaritmo dessa chance. Deu 90% para a certa: perda 0,105. Deu 50%: 0,693. Deu 10%: 2,303. Deu 1%: 4,605. Quanto mais surpresa, mais a nota cresce.	Fórmula: perda = −ln(p); tabela com os 4 valores subindo. REAL (conta)
36–48 s	Isso é calculado em cada token de trilhões de tokens, e a média é o número que o treino tenta derrubar. Gramática, fatos, raciocínio: tudo aparece como efeito colateral de ficar menos surpreso com texto humano.	Sirene; um gráfico de perda caindo ao longo do treino. ILUSTRATIVO
48–58 s	Bônus: eleve e à perda e você tem a perplexidade. Perda de 0,693 dá perplexidade 2: é como se, em média, a IA estivesse em dúvida entre duas opções.	Fórmula: perplexidade = e^perda; e^0,693 = 2. REAL (conta)
58–65 s	Fechamento padrão.	Placa de aviso

12 · LONGO · Gradiente descendente e backpropagation (110 s)

Capa: **Como bilhões de números aprendem** · Termos na tela: peso · gradiente · gradiente descendente · taxa de aprendizado · backpropagation · regra da cadeia · lote

Tempo	Narração	Na tela
0–4 s	Uma IA nasce com bilhões de números aleatórios. Ela fala só lixo. Como esses números viram conhecimento?	Caixa de resposta com letras aleatórias

Tempo	Narração	Na tela
4–10 s	Com duas ideias: gradiente descendente e backpropagation.	Placa: CONTROLE DE QUALIDADE
10–24 s	Imagina que você está numa montanha, no escuro, e quer chegar no vale. Você não vê o caminho, mas sente a inclinação do chão. Dá um passo para baixo. Sente de novo. Outro passo.	Um bonequinho de contorno preto descendo uma encosta no escuro, com uma lanterna fraca
24–40 s	A altura da montanha é a perda, o número da surpresa. Cada direção é um dos bilhões de pesos. O gradiente diz, para cada peso, se aumentar ou diminuir piora a perda, e quanto.	A montanha vira um gráfico; setas em cada peso dizendo + ou −
40–52 s	Então a gente mexe cada peso um pouquinho na direção contrária. O tamanho desse passo se chama taxa de aprendizado. Passo grande demais, você pula o vale. Pequeno demais, nunca chega.	Fórmula: peso ← peso − taxa × gradiente; dois exemplos de passo
52–70 s	O problema: como calcular o gradiente de bilhões de pesos ao mesmo tempo? A resposta é a backpropagation, popularizada em 1986. A perda é calculada no fim, e a regra da cadeia do cálculo leva a culpa de volta, camada por camada, até o começo.	Sirene; o erro descendo de volta pelos 96 andares da linha de montagem, acendendo cada um
70–84 s	Na prática, a IA não aprende um exemplo por vez. Ela vê um lote com milhões de tokens, calcula a média dos gradientes e dá um passo. Depois outro lote. Por semanas ou meses, em milhares de GPUs.	Lotes de caixas entrando; contador de passos girando
84–100 s	Ninguém programou o que cada peso significa. O conhecimento é o que sobra depois de milhões de pequenos passos ladeira abaixo. É por isso que nem quem constrói o modelo sabe exatamente o que cada número faz.	Zoom out: um mar de números estabilizando

Tempo	Narração	Na tela
100–110 s	Fechamento padrão.	Placa de aviso

13 · LONGO · Do modelo base ao assistente: SFT, RLHF e DPO (120 s)

Capa: **O treino que transformou o GPT em ChatGPT** · Termos na tela: modelo base · SFT · modelo de recompensa · RLHF · PPO · DPO

Tempo	Narração	Na tela
0–4 s	Em 2022, um modelo de 1,3 bilhão de parâmetros foi preferido por avaliadores humanos a um de 175 bilhões.	Uma caixa pequena vencendo uma caixa gigante num pódio. REAL (InstructGPT, OpenAI, 2022)
4–10 s	O pequeno não era maior. Era mais bem treinado para ser assistente. Vou te mostrar as três etapas.	Placa: CONTROLE DE QUALIDADE
10–26 s	Etapa 0, pré-treino: o modelo lê trilhões de tokens prevendo a próxima palavra. No fim, ele completa texto, mas não obedece. Pergunte a capital da França e ele pode responder com mais perguntas, como se continuasse uma lista de exercícios.	Caixa "capital da França?" gerando "capital da Alemanha? capital da Itália?"
26–40 s	Etapa 1, ajuste supervisionado, o SFT: pessoas escrevem dezenas de milhares de exemplos de pergunta e resposta ideal, e o modelo é treinado em cima deles. Ele aprende o formato de um assistente.	Pilha de fichas "pergunta → resposta ideal"
40–58 s	Etapa 2, o modelo de recompensa: o assistente gera várias respostas para a mesma pergunta, e pessoas ordenam da melhor para a pior. Com isso se treina um segundo modelo que prevê qual resposta um humano preferiria: um juiz automático.	Inspetores ordenando 4 caixas; um juiz robótico (sem rosto, uma caixa com balança) aprendendo

Tempo	Narração	Na tela
58–76 s	Etapa 3, o RLHF: o assistente gera respostas, o juiz dá nota, e um algoritmo de aprendizado por reforço, o PPO, ajusta o assistente para tirar notas maiores. Com um freio: ele não pode se afastar demais do modelo original, senão aprende a enganar o juiz.	Loop: assistente → juiz → nota → ajuste; uma corda presa ao modelo original
76–92 s	Em 2023 surgiu um atalho, o DPO: pula o juiz e treina o modelo direto nos pares "essa resposta é melhor que aquela". Mais simples, e hoje muito usado.	Sirene; o juiz sai de cena; pares de caixas com ✓ e ✗
92–108 s	Essa etapa de preferência é o que dá o jeito educado, o formato e as recusas. E é também de onde vem a bajulação: se humanos preferem quem concorda com eles, o modelo aprende a concordar.	Caixa de resposta com um joinha desenhado
108–120 s	Fechamento padrão.	Placa de aviso

14 · O que são 175 bilhões de parâmetros, e quanto pesam (60 s)

Capa: **Quanto pesa uma IA** · Termos na tela: parâmetro · peso · bits · GPU · VRAM

Tempo	Narração	Na tela
0–3 s	O GPT-3 tinha 175 bilhões de parâmetros. Mas o que é um parâmetro?	Contador girando até 175.000.000.000. REAL (GPT-3, 2020)
3–8 s	É só um número. E dá para calcular quanto espaço uma IA ocupa.	Placa: ALMOXARIFADO
8–20 s	Cada parâmetro é um número ajustado no treino: um peso das multiplicações que você viu na atenção e na MLP. A IA inteira é uma lista enorme desses números.	Uma caixa abre e cai uma chuva de números decimais

Tempo	Narração	Na tela
20–32 s	Guardado em 16 bits, cada número ocupa 2 bytes. 175 bilhões vezes 2 bytes: 350 gigabytes. Só os pesos.	Conta: 175 bi × 2 bytes = 350 GB. REAL (conta)
32–44 s	Uma GPU topo de linha para IA tem cerca de 80 gigabytes de memória. O modelo não cabe numa só. Ele é fatiado e espalhado em várias, que conversam o tempo todo.	Sirene; o modelo cortado em 5 fatias, uma em cada GPU desenhada
44–54 s	E isso é só para rodar. Para treinar, você ainda guarda gradientes e outros dados para cada peso, o que multiplica a memória várias vezes.	Pilha de caixas crescendo ao lado de cada GPU
54–60 s	Fechamento padrão.	Placa de aviso

15 · Quantização: como uma IA cabe no seu computador (60 s)

Capa: **Como encolher uma IA** · Termos na tela: quantização · 16 bits · 8 bits · 4 bits · precisão

Tempo	Narração	Na tela
0–3 s	Um modelo de 70 bilhões de parâmetros ocupa 140 gigabytes. Dá para rodar em 35.	Uma caixa enorme encolhendo para um quarto. REAL (conta)
3–8 s	O truque se chama quantização: arredondar os números.	Placa: ALMOXARIFADO
8–20 s	Em 16 bits, cada peso pode assumir dezenas de milhares de valores diferentes. Mas a rede não precisa de tanta precisão.	Uma régua com marcações finíssimas
20–34 s	Com 8 bits, são 256 valores possíveis por peso. 70 bilhões vezes 1 byte: 70 gigabytes. Com 4 bits, só 16 valores: 35 gigabytes.	Réguas com cada vez menos marcas; 140 → 70 → 35 GB. REAL (conta)

Tempo	Narração	Na tela
34–46 s	Para não perder muito, os pesos são agrupados em blocos pequenos, cada um com a sua própria escala. Assim os 16 valores ficam bem distribuídos onde importa.	Blocos de caixas, cada um com uma régua própria
46–54 s	Funciona porque a rede tolera um pouco de ruído. Em 8 bits a perda costuma ser pequena; em 4, aparece mais; abaixo disso, a qualidade cai rápido.	Sirene; três caixas de resposta, a última com rachaduras
54–60 s	Fechamento padrão.	Placa de aviso

Vídeos 16 a 20

16 · Leis de escala e o erro de 2020 (65 s)

Capa: **O GPT-3 foi mal alimentado** · Termos na tela: leis de escala · computação · tokens por parâmetro · Chinchilla

Tempo	Narração	Na tela
0–3 s	O GPT-3 era grande demais para a quantidade de texto que leu. E isso foi descoberto com uma conta.	Uma caixa gigante com um prato quase vazio na frente
3–8 s	A conta se chama lei de escala.	Placa: ARQUIVO HISTÓRICO
8–22 s	Em 2020, a OpenAI mostrou que a perda cai de forma previsível quando você aumenta três coisas: tamanho do modelo, quantidade de dados e poder de computação. Dá para prever o resultado antes de treinar.	Três alavancas; uma curva descendo suave. ILUSTRATIVO
22–36 s	A leitura da época foi: aumente o modelo. O GPT-3 tinha 175 bilhões de parâmetros e foi treinado com cerca de 300 bilhões de tokens. Menos de 2 tokens por parâmetro.	Conta: 300 bi ÷ 175 bi ≈ 1,7. REAL (GPT-3, 2020)

Tempo	Narração	Na tela
36–50 s	Em 2022, a DeepMind refez as contas: para o mesmo orçamento, o ideal é cerca de 20 tokens por parâmetro. O modelo deles, o Chinchilla, com 70 bilhões, treinado com 1,4 trilhão de tokens, venceu um modelo deles de 280 bilhões.	Sirene; caixa média bem alimentada vencendo a gigante. REAL (Chinchilla, 2022)
50–58 s	Hoje se vai muito além disso: modelos pequenos treinados com trilhões de tokens, porque um modelo menor custa menos para rodar milhões de vezes por dia.	Uma caixa pequena com uma montanha de pratos
58–65 s	Fechamento padrão.	Placa de aviso

17 · Por que contexto longo é caro: atenção quadrática (55 s)

Capa: **Dobrar o texto custa 4×** · Termos na tela: janela de contexto · complexidade quadrática · n^2

Tempo	Narração	Na tela
0–3 s	Dobre o tamanho do texto e a atenção faz quatro vezes mais contas.	"2×" virando "4×"
3–8 s	Isso explica por que contexto longo é caro e lento.	Placa: SALA DE REUNIÃO
8–20 s	Na atenção, cada token compara a sua query com a key de todos os outros. Com n tokens, são cerca de n vezes n comparações. Em cada cabeça, em cada camada.	Grade de n × n se preenchendo
20–34 s	Mil tokens: um milhão de comparações. Dez mil: cem milhões. Cem mil tokens, que é um livro: dez bilhões.	Contador explodindo: $10^6 \rightarrow 10^8 \rightarrow 10^{10}$. REAL (conta)

Tempo	Narração	Na tela
34–46 s	Técnicas como o FlashAttention reorganizam a conta para usar melhor a memória da GPU e deixam tudo muito mais rápido. Mas a escala continua quadrática.	Sirene; a grade fica mais organizada, mas do mesmo tamanho
46–50 s	Moral: não cole o livro inteiro se três páginas resolvem.	Uma pilha de papel encolhendo para 3 folhas
50–55 s	Fechamento padrão.	Placa de aviso

18 · KV cache: por que a primeira palavra demora (60 s)

Capa: **Por que a IA trava no começo** · Termos na tela: KV cache · prefill · decode · tempo até o primeiro token

Tempo	Narração	Na tela
0–3 s	A IA demora para começar e depois dispara. Isso tem uma explicação técnica precisa.	Cronômetro: pausa longa, depois palavras rápidas
3–8 s	Ela guarda contas num armário. Esse armário se chama KV cache.	Placa: ARQUIVO
8–22 s	Fase 1, prefill: a IA processa o seu prompt inteiro de uma vez, em paralelo. Para cada token, em cada camada, calcula a key e o value. É esse trabalho que você sente como a espera inicial.	Todas as caixas do prompt entrando juntas; tempo até o primeiro token marcado
22–36 s	Esses K e V vão para o armário. Fase 2, decode: para gerar cada nova palavra, ela só calcula o token novo e consulta o armário para comparar com os anteriores. Nada é recalculado.	Uma caixa nova por vez; ela abre o armário e consulta
36–48 s	O preço: o armário cresce a cada token, em cada camada. Em contextos muito longos, ele pode ocupar mais memória da GPU do que o próprio modelo.	Sirene; o armário ficando maior que a fábrica

Tempo	Narração	Na tela
48–54 s	Por isso modelos novos compartilham keys e values entre várias cabeças: para o armário caber.	Várias cabeças apontando para a mesma gaveta
54–60 s	Fechamento padrão.	Placa de aviso

19 · Por que a resposta custa mais caro que a pergunta (55 s)

Capa: **Pagar para ler × pagar para escrever** · Termos na tela: tokens de entrada · tokens de saída · paralelo · sequencial · largura de banda de memória

Tempo	Narração	Na tela
0–3 s	Nas APIs de IA, cada token que ela escreve costuma custar várias vezes mais do que cada token que ela lê.	Duas etiquetas de preço: entrada e saída, a de saída bem maior
3–8 s	Não é ganância. É física da GPU.	Placa: EXPEDIÇÃO
8–22 s	Ler o seu prompt acontece em paralelo: milhares de tokens processados juntos, numa única passada pelos pesos. A GPU trabalha cheia.	Mil caixas entrando juntas numa esteira larga
22–36 s	Escrever é sequencial: um token por vez, porque cada um depende do anterior. E para cada token a GPU precisa ler da memória todos os bilhões de pesos do modelo, para fazer pouca conta.	Uma caixa por vez numa esteira estreita; um caminhão de pesos indo e voltando a cada caixa
36–46 s	O gargalo não é calcular. É transportar os pesos da memória para o processador. Por isso a saída ocupa a máquina por mais tempo e custa mais.	Sirene; placa "GARGALO: MEMÓRIA"
46–50 s	Na prática: respostas longas custam caro. Peça só o tamanho que precisa.	Caixa de resposta encolhendo
50–55 s	Fechamento padrão.	Placa de aviso

20 · Prompt caching (55 s)

Capa: **O desconto escondido da IA** · Termos na tela: prompt caching · prefixo · cache hit · cache miss

Tempo	Narração	Na tela
0–3 s	Se o começo do seu prompt é sempre igual, você está pagando para a IA ler a mesma coisa de novo.	Um manual igual entrando na esteira repetidas vezes, com uma moeda caindo a cada vez
3–8 s	Existe um armário para isso.	Placa: ARQUIVO
8–22 s	Lembra do KV cache? Os provedores podem guardar esse armário entre uma chamada e outra. Se o início do prompt for idêntico ao da chamada anterior, a IA pula o prefill dessa parte.	O armário de uma chamada sendo reaproveitado pela seguinte
22–34 s	Isso se chama prompt caching. A parte em cache sai bem mais barata e a resposta começa mais rápido.	Etiqueta de desconto na parte guardada
34–46 s	A regra de ouro: tem que ser o mesmo começo, caractere por caractere. Mudou uma vírgula no início, perdeu o cache de tudo que vem depois.	Sirene; uma vírgula diferente e o armário inteiro esvaziando
46–50 s	Então: o que é fixo vai no começo, o que muda vai no final.	Pilha: instruções e documentos embaixo, pergunta em cima
50–55 s	Fechamento padrão.	Placa de aviso

Vídeos 21 a 25

21 · Mixture of Experts: o modelo que usa só parte do cérebro (60 s)

Capa: **47 bilhões, mas usa 13** · Termos na tela: Mixture of Experts · especialista · roteador · parâmetros ativos

Tempo	Narração	Na tela
0–3 s	Esse modelo tem 47 bilhões de parâmetros, mas usa só uns 13 bilhões por palavra.	Caixa gigante com só um pedaço aceso. REAL (Mixtral 8x7B, Mistral, 2023)
3–8 s	A técnica se chama Mixture of Experts.	Placa: LINHA DE MONTAGEM
8–20 s	Lembra da MLP, a parte de cada camada onde cada token é processado sozinho? Num MoE, em vez de uma MLP, existem várias. No Mixtral, oito por camada. São os "especialistas".	Um andar com 8 máquinas iguais lado a lado
20–32 s	Antes delas, uma pequena rede, o roteador, olha cada token e escolhe as duas melhores máquinas para ele. Só essas duas trabalham. As outras seis ficam paradas.	Um guarda de trânsito mandando cada caixa para 2 das 8 máquinas
32–44 s	Resultado: o conhecimento de um modelo grande com o custo por token de um modelo bem menor.	Balança: "conhecimento: grande" × "custo: pequeno"
44–54 s	E a pegadinha: os especialistas não viram "o de matemática" e "o de história". Ao analisar o Mixtral, os autores não acharam especialização clara por assunto. A divisão que a rede aprende não é a que a gente imaginaria.	Sirene; etiquetas "MATEMÁTICA" e "HISTÓRIA" caindo das máquinas
54–60 s	Fechamento padrão.	Placa de aviso

22 · Speculative decoding: o modelo pequeno que chuta (60 s)

Capa: **Um modelo chuta, o outro confere** · Termos na tela: speculative decoding · modelo rascunho · verificação paralela

Tempo	Narração	Na tela
0–3 s	Algumas IAs respondem mais rápido porque um modelo menor fica chutando o que a grande vai dizer.	Uma caixinha correndo na frente de uma caixa grande

Tempo	Narração	Na tela
3–8 s	E o resultado final é o mesmo que a grande daria sozinha.	Placa: EXPEDIÇÃO
8–20 s	Lembra: escrever é lento porque é um token por vez, e cada um exige uma passada inteira pelo modelo grande. Mas conferir vários tokens de uma vez é rápido, porque é em paralelo, como ler o prompt.	Esteira estreita (escrever) × esteira larga (conferir)
20–34 s	Então: um modelo pequeno e rápido rascunha, digamos, cinco tokens. O modelo grande confere os cinco numa única passada e vê até onde concorda.	5 caixas rascunhadas; a máquina grande carimba ✓ ✓ ✓ ✗
34–46 s	Ele aceita os três primeiros, troca o quarto pela escolha dele, e o pequeno recomeça dali. Em vez de um token por passada, saíram quatro.	Três caixas verdes seguem; a quarta é trocada
46–54 s	Com a regra de aceitação certa, a resposta segue exatamente as probabilidades do modelo grande. É velocidade de graça.	Sirene; selo "MESMO RESULTADO"
54–60 s	Fechamento padrão.	Placa de aviso

23 · Tool calling por dentro: a IA só escreve JSON (65 s)

Capa: **A IA nunca entrou na internet** · Termos na tela: tool calling · function calling · JSON · schema

Tempo	Narração	Na tela
0–3 s	Quando a IA "pesquisa na internet", ela não pesquisa nada. Ela escreve um pedido.	Caixa de resposta com uma lupa riscada
3–8 s	Quem pesquisa é o programa em volta dela. Olha o mecanismo.	Placa: SALA DA DIRETORIA

Tempo	Narração	Na tela
8–20 s	O app coloca no contexto uma lista de ferramentas: nome, descrição do que faz e um schema, que diz quais campos ela aceita. Tudo como texto.	Um cardápio de ferramentas grampeado no manual: "buscar_web(consulta)", "previsao_tempo(cidade)"
20–34 s	Você pergunta se vai chover em Recife. O modelo foi treinado para, nessa situação, gerar um bloco estruturado em vez de texto normal: nome da ferramenta e argumentos.	Na tela: { "name": "previsao_tempo", "arguments": { "cidade": "Recife" } }
34–46 s	O app lê esse bloco, chama a API de previsão de verdade e cola o resultado de volta na conversa, como se fosse uma nova mensagem.	O bloco sai da fábrica, vai até um prédio "API" e volta com "80% de chuva"
46–56 s	Aí o modelo roda de novo, agora com o resultado no contexto, e escreve a resposta. Ele nunca clicou, nunca navegou. Só escreveu JSON e leu a resposta.	Sirene; a resposta final sai em verde
56–65 s	Fechamento padrão.	Placa de aviso

24 · MCP por dentro (70 s)

Capa: **O que é MCP de verdade** · Termos na tela: MCP · cliente · servidor · JSON-RPC · tools · resources · prompts

Tempo	Narração	Na tela
0–3 s	Todo mundo fala de MCP. Pouca gente sabe que ele é só um jeito padronizado de fazer o que você viu no vídeo das ferramentas.	Uma tomada universal desenhada
3–8 s	Model Context Protocol, publicado pela Anthropic em novembro de 2024, como padrão aberto.	Placa: SALA DA DIRETORIA · ficha "MCP · 2024"

Tempo	Narração	Na tela
8–22 s	O problema: com 10 apps de IA e 10 serviços, cada par precisava de uma integração própria. Cem integrações. Com um padrão, cada um implementa uma vez: 10 mais 10.	Grade de 100 fios virando 20 fios ligados a um barramento. REAL (conta)
22–38 s	Do lado do serviço, existe um servidor MCP: um programa que embrulha o Google Drive, o Slack, um banco de dados. Do lado do app, um cliente MCP. Eles conversam por mensagens em JSON-RPC, um formato simples de pedido e resposta.	Dois prédios: "CLIENTE" e "SERVIDOR", trocando envelopes JSON
38–52 s	O servidor oferece três coisas: tools, ações que o modelo pode pedir; resources, dados que o app pode ler; e prompts, modelos de instrução prontos. As tools viram exatamente aquela lista de ferramentas no contexto.	Três gavetas: TOOLS · RESOURCES · PROMPTS
52–62 s	E o cuidado: a descrição de cada ferramenta entra no contexto como texto. Um servidor malicioso pode esconder instruções ali. Conecte só servidores em que você confia.	Sirene; uma descrição com uma linha escondida em vermelho
62–70 s	Fechamento padrão.	Placa de aviso

25 · LONGO · O que é um agente, de verdade: o loop (100 s)

Capa: **Agente é um while** · Termos na tela: agente · loop · ReAct · observação · erro composto

Tempo	Narração	Na tela
0–4 s	Agente de IA parece mágica. Por dentro, é um loop de poucas linhas de código.	Um laço de esteira fechado
4–10 s	Vou te mostrar o loop, e a conta que explica por que agentes erram tanto.	Placa: EXPEDIÇÃO

Tempo	Narração	Na tela
10–26 s	O padrão vem de um artigo de 2022 chamado ReAct: pensar, agir, observar. O modelo pensa no próximo passo, pede uma ferramenta, recebe o resultado e pensa de novo.	Três estações em círculo: PENSAR → AGIR → OBSERVAR. Ficha "ReAct · 2022"
26–42 s	Em código: enquanto não terminou, mande o histórico para o modelo. Se ele pediu uma ferramenta, execute e adicione o resultado ao histórico. Se ele respondeu sem pedir nada, acabou.	Pseudocódigo: enquanto não_terminou: resposta = modelo(histórico); se pediu_ferramenta: histórico += executar(...); senão: fim
42–56 s	Repara: a cada volta, o histórico cresce. Todo resultado de busca, todo arquivo lido, tudo entra no contexto. O agente vai ficando mais caro e mais lento a cada passo.	Pilha de caixas crescendo a cada volta
56–74 s	E agora a conta. Se cada passo tem 95% de chance de dar certo, 10 passos seguidos dão certo só 60% das vezes. Vinte passos: 36%. Com 99% por passo, vinte passos ainda caem para 82%.	Sirene; contas na tela: $0{,}95^{10} \approx 60\%$ · $0{,}95^{20} \approx 36\%$ · $0{,}99^{20} \approx 82\%$. REAL (conta)
74–88 s	É por isso que bons agentes têm pontos de checagem: limite de passos, verificação do resultado, e pedido de aprovação humana antes de qualquer ação que não dá para desfazer.	Placas: LIMITE DE PASSOS · VERIFICAÇÃO · APROVAÇÃO HUMANA
88–100 s	Fechamento padrão.	Placa de aviso

Vídeos 26 a 30

26 · LONGO · RAG por dentro, passo a passo (110 s)

Capa: **Como a IA "lê" seus documentos** · Termos na tela: RAG · chunk · embedding · banco vetorial · top-k · reranking · busca híbrida

Tempo	Narração	Na tela
0–4 s	Quando você manda a IA responder com base nos seus 500 documentos, ela não lê os 500. Lê uns cinco pedaços.	500 pastas; só 5 folhas iluminadas
4–10 s	O nome disso é RAG. E cada etapa dele pode dar errado de um jeito diferente.	Placa: ALMOXARIFADO
10–24 s	Antes de qualquer pergunta, vem a indexação. Cada documento é cortado em pedaços, os chunks, de algumas centenas de tokens, geralmente com um pouco de sobreposição para não cortar uma ideia no meio.	Guilhotina cortando documentos em fatias que se sobrepõem levemente
24–36 s	Cada chunk passa por um modelo de embedding e vira um vetor, uma seta no mapa de significados. Esses vetores vão para um banco vetorial.	Fatias virando setas e sendo guardadas em prateleiras numeradas
36–50 s	Na hora da pergunta, a pergunta também vira um vetor. O sistema busca os chunks cujas setas apontam mais na mesma direção, pela similaridade de cosseno, e pega os k melhores. Digamos, cinco.	A seta da pergunta procura as 5 mais alinhadas; ângulos destacados
50–60 s	Muitos sistemas ainda passam esses candidatos por um reranker, um modelo que lê pergunta e trecho juntos e reordena com mais precisão.	Uma máquina reordenando as 5 folhas
60–72 s	Por fim, os trechos são colados no prompt com uma instrução do tipo: responda só com base nisso e cite de onde tirou. Só aí o modelo gera a resposta.	As 5 folhas grampeadas no manual entrando na fábrica

Tempo	Narração	Na tela
72–96 s	Onde quebra: o chunk cortou a informação ao meio; a pergunta usa palavras diferentes do documento; embeddings são ruins com códigos, números e nomes exatos, por isso se combina com busca por palavra-chave; e a resposta certa estava no sexto chunk, não nos cinco.	Sirene; quatro placas de DEFEITO, uma por falha
96–100 s	Quando um RAG erra, quase nunca é o modelo. É a busca.	Uma lupa com a etiqueta "O PROBLEMA ESTÁ AQUI"
100–110 s	Fechamento padrão.	Placa de aviso

27 · Modelos de raciocínio: o que é o "pensando..." (75 s)

Capa: **O que a IA faz enquanto "pensa"** · Termos na tela: modelo de raciocínio · chain-of-thought · aprendizado por reforço · recompensa verificável · computação no teste

Tempo	Narração	Na tela
0–3 s	Quando aparece "pensando...", a IA está escrevendo. Só que para ela mesma.	Uma caixa com balão de pensamento cheio de texto cinza
3–8 s	E aprender a escrever esse rascunho exigiu um tipo novo de treino.	Placa: CONTROLE DE QUALIDADE
8–20 s	Lembra que cada token é uma passada pela fábrica? Mais tokens antes da resposta significa mais computação gasta no problema. Um rascunho de mil tokens é mil passadas pensando.	Contador de passadas subindo enquanto o rascunho cresce
20–38 s	O treino: dão ao modelo problemas com resposta que dá para conferir automaticamente, como contas e código com testes. Ele tenta, escreve o raciocínio que quiser, e só ganha recompensa se a resposta final estiver certa.	Problemas entrando; um carimbo ✓ só no final da folha. Fichas: "o1 · 2024", "DeepSeek-R1 · 2025"

Tempo	Narração	Na tela
38–52 s	Ninguém ensina como pensar. Com aprendizado por reforço, comportamentos úteis aparecem sozinhos: conferir conta, voltar atrás, escrever "espera, errei". O DeepSeek publicou exemplos disso em 2025.	Sirene; no rascunho aparece "espera..." e uma seta de volta
52–66 s	Dois cuidados. Os tokens de pensamento são cobrados como saída. E pesquisas mostram que o raciocínio escrito nem sempre é o que de fato levou à resposta. Leia como pista, não como confissão.	Duas placas de aviso: CUSTO · FIDELIDADE
66–75 s	Fechamento padrão.	Placa de aviso

28 · Como a IA vê uma imagem (60 s)

Capa: **Uma imagem vale 196 palavras** · Termos na tela: Vision Transformer · patch · token visual · multimodal

Tempo	Narração	Na tela
0–3 s	Para a IA, uma foto vira uma frase de 196 palavras.	Uma foto quebrando em um mosaico
3–8 s	A técnica vem de um artigo de 2020 chamado "Uma imagem vale 16 por 16 palavras".	Placa: TOKENIZADOR · ficha "Vision Transformer · 2020"
8–22 s	A imagem é cortada em quadrados de 16 por 16 pixels. Uma imagem de 224 por 224 vira uma grade de 14 por 14: 196 quadrados.	Guilhotina cortando a foto em grade 14 × 14; contador 196. REAL (conta)
22–34 s	Cada quadrado tem 16 vezes 16 pixels, com 3 cores cada: 768 números. Uma multiplicação aprendida transforma isso num vetor, igual ao embedding de uma palavra.	Um quadrado virando uma fita de 768 números. REAL (conta)

Tempo	Narração	Na tela
34–46 s	A partir daí é um Transformer normal: os quadrados ganham posição e fazem atenção entre si. O canto com a orelha presta atenção no canto com o focinho.	Sala de reunião com quadrados de imagem ligados por fios
46–54 s	Nos chats multimodais, esses tokens visuais entram na mesma fila que as suas palavras. Para o modelo, é tudo sequência.	Sirene; caixas de imagem e caixas de texto na mesma esteira
54–60 s	Fechamento padrão.	Placa de aviso

29 · LONGO · Como a IA gera imagem: difusão (100 s)

Capa: **Toda imagem de IA começa como chiado** · Termos na tela: difusão · ruído · denoising · espaço latente · guidance

Tempo	Narração	Na tela
0–4 s	Toda imagem gerada por IA começa como chiado de TV.	Um quadro de chiado na esteira
4–10 s	O ChatGPT escreve uma palavra por vez. Os geradores de imagem fazem outra coisa: limpam sujeira.	Placa: LABORATÓRIO
10–26 s	No treino, pegam milhões de imagens reais e vão adicionando ruído aos poucos, em vários passos, até sobrar só chiado. A rede é treinada para uma única tarefa: olhar uma imagem suja e prever qual ruído foi adicionado.	Uma foto ficando mais suja passo a passo, da esquerda para a direita
26–42 s	Na geração, o processo roda ao contrário. Começa do chiado puro. A rede prevê o ruído, uma parte é removida, e repete por dezenas de passos. Uma imagem vai surgindo do nada.	Mesma esteira andando para trás: chiado → borrão → forma → imagem

Tempo	Narração	Na tela
42–58 s	E o texto? O seu prompt vira um vetor por um modelo de texto, e esse vetor entra na rede por atenção a cada passo. Ele não desenha nada. Ele empurra a limpeza numa direção.	Uma seta "gato de chapéu" apontando para dentro da máquina de limpeza
58–72 s	Um truque chamado guidance: a cada passo, a rede prevê a limpeza com o prompt e sem o prompt, e o sistema exagera a diferença. Guidance alto obedece mais ao texto, mas a imagem fica artificial.	Sirene; botão GUIDANCE; duas imagens: uma fiel e saturada, outra solta
72–88 s	E para ser rápido, a limpeza não acontece nos pixels. No Stable Diffusion original, uma imagem de 512 por 512 era comprimida para uma grade de 64 por 64 num espaço latente, limpa ali, e só no fim descomprimida.	Uma imagem grande vira um cubo pequeno, é limpa e volta a crescer. REAL (Stable Diffusion, 2022)
88–100 s	Fechamento padrão.	Placa de aviso

30 · Superposição: mais conceitos que neurônios (75 s)

Capa: **A IA guarda mais do que cabe** · Termos na tela: neurônio · superposição · polissêmico · sparse autoencoder · feature

Tempo	Narração	Na tela
0–3 s	Uma IA guarda muito mais conceitos do que tem neurônios. E isso é um problema para quem tenta entender ela.	Uma gaveta pequena com mil coisas saindo
3–8 s	Esse fenômeno se chama superposição.	Placa: LABORATÓRIO
8–22 s	Se cada neurônio guardasse um conceito, seria fácil: achar o neurônio do "cachorro". Mas na prática um mesmo neurônio acende para coisas sem relação nenhuma. São neurônios polissêmicos.	Um neurônio com três etiquetas: "cachorro" · "código Python" · "tristeza"

Tempo	Narração	Na tela
22–36 s	O motivo: em espaços com milhares de dimensões, cabem muito mais direções quase independentes do que dimensões. A rede usa isso para espremer conceitos, cada um como uma combinação de vários neurônios.	Muitas setas num espaço, todas quase perpendiculares. ILUSTRATIVO
36–52 s	Para separar a mistura, pesquisadores treinam uma segunda rede, um sparse autoencoder, que decompõe a atividade interna em peças que raramente acendem juntas. Em 2024, a Anthropic extraiu milhões dessas peças de um modelo Claude.	Uma máquina desembaraçando um novelo em fios separados. REAL ("Scaling Monosemanticity", Anthropic, 2024)
52–66 s	E elas fazem sentido: uma acende para a Ponte Golden Gate, outra para código com bug, outra para bajulação. Amplificando a da ponte, o Claude passou a dizer que era a própria ponte.	Sirene; três etiquetas acendendo; uma caixa saindo com uma ponte desenhada
66–75 s	Fechamento padrão.	Placa de aviso